Laporan UTS 1

PEMROSESAN BAHASA ALAMI



DIBUAT OLEH :

Elvinda Kenia Tri Prastika
245314106

PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS SANATA DHARMA
YOGYAKARTA
2026

A. Tujuan

Bangun sistem klasifikasi sentimen bahasa Indonesia dan lakukan eksperimen untuk mengetahui bagaimana preprocessing dan fitur linguistik memengaruhi performa classifier.

B. Data Audit

1. Jumlah dan Pembagian Data
   Dataset yang digunakan adalah SmSA. Berdasarkan Output data training terdiri dari 11.000 data, kemudian data dibagi menjadi 80% data training sehingga datanya menjadi 8.800 data dan dibagi juga 20% data devolopment sehingga menjadi 2.200 data dengan menggunakan random_state=42. Data validation terdiri dari 1.260 data dan dipisahkan dengan data training. Jadi jumlah keseluruhan data adalah 12.260 data.
2. Distribusi Kelas
   Berdasarkan hasil output kelas positive merupakan kelas dengan jumlah data terbanyak itu yaitu sebesar 58,33% pada data training, sedangkan kelas negatif jumlah data sebesar 31,24% dan jumlah data neutral sebesar 10,43%. Distribusi kelas pada data training, development dan validation memiliki output yang hampir sama . Meskipun pembagian data sudah mempertahankan proporsi kelas, dataset masih mengalami ketidaksimbangan kelas karena jumlah data positive jauh lebih banyak daripada jumlah data kelas neutral.
3. Pemeriksaan Missing Value
   Berdasarkan hasil output pada data training dan juga data validation tidak terdapat missing value, teks kosong, maupun label kosong .
4. Pemeriksaan Data Duplikat
   Berdasarkan hasil output pada data training terdapat 67 data duplikat, sedangkan pada data validation tidak terdapat adanya data duplikat
5. Distribusi Panjang Teks
   Berdasarkan hasil output rata rata panjang teks pada data training adalah 32,93 kata, sedangkan rata rata panjang teks pada data validation adalah 32,52 kata. Panjang teks maksimum pada data training yaitu 110 kata sedangkan panjang teks maksimum pada data validation adalah 100 kata .Panjang teks maksimum untuk kedua data tersebut adalah 1 kata. Jadi hal ini menunjukkan bahwa panjang teks antara data training dan juga data validation hampir sama.
6. Contoh dan karakteristik Bahasa
   Kelas positive umumnya berisi pengalaman atau ulasan yang baik , kelas negative berisi keluhan sedangkan kelas neutral berisi informasi atau peristiwa tanpa penilaian yang jelas. Dari hasil output pemeriksaan karakteristik bahasa ditemukannya kata atau bahasa informal seperti “enggak”, “nggak”, “aja”, “banget”, dan “kayak”, kata "banget" merupakan salah satu kata informal yang cukup sering ditemukan, yaitu pada 1.215 teks. Untuk negasi ditemukan hasil “tidak”, “bukan”, “belum”, “jangan”, dan “tak”, dengan kata “tidak” ditemukan 3.478 . Terdapat juga 9.431 teks yang mengandung tanda baca. Dalam data tidak ditemukan adanya emoticon. Untuk pemeriksaan awal kemungkinan code-mixing terdapat beberapa kata bahasa inggris pada data seperti “bad” pada 10 teks,

"recommended" pada 10 teks, "service" pada 15 teks, "unboxing" pada 1 teks, "food" pada 54 teks, dan "wifi" pada 60 teks.

7. Potensi Imbalance, Noise dan Bias
   Dari dataset ini dapat dilihat bahwa kelas positive paling banyak sedangkan kelas neutral paling sedikit, jadi dataset ini berpotensi class imbalance. Sehingga model bisa lebih mudah menebak kelas mayoritas dan kesulitan mengenali kelas minoritas. Selain itu noise juga berpotensi muncul karena adanya penggunaan katakata nonbaku, singkatan, salah ketik, campuran bahasa Indonesia dengan bahasa inggris serta adanya kata negasi. Hal hal tersebut dapat menjadi pertimbangan saat preprocessing dan juga pengembangan fitur.

C. Model Baseline

1. Accuracy
   Berdasarkan output Accuracy yang di dapatkan dalam data adalah 0.8745
   Yang berarti model berhasil memprediksi 87,45% data dengan benar
2. Precision, Recall, dan F1-score per kelas

Classification:

	precision	recall	f1-score
negative	0.8093	0.8341	0.8215
neutral	0.9244	0.6913	0.7910
positive	0.9030	0.9291	0.9159

3. Macro-F1
   Berdasarkan output Macro-F1 yang didapatkan dalam data sebesar 0.842805
4. Confusion Matrix

CONFUSION MATRIX

	Predicted Positive	Predicted Negative	Predicted Neutral
Prediksi Positive	1192	84	7
Prediksi Negative	108	573	6
Prediksi Neutral	20	51	159

   Berdasarkan hasil confusion matrix, data menunjukkan hasil yang cukup baik pada kelas mayoritas, tetapi terdapat kendala pada kelas minoritas, Untuk kelas positive terdapat 1.283 data positive dan sebanyak 1.192 berhasil diprediksi dengan benar. Kelas negative terdapat 687 data negative dan sebanyak 573 data berhasil diprediksi dengan benar. Dan terdapat 230 data neutral dan 159 data berhasil diprediksi dengan benar.

D. Eksperimen Preprocessing

1. Pada experimen EXP-1 dilakukan normalisasi teks informal untuk mengubah kata tidak baku menjadi kata baku, contohnya “gak”,”gk”, dan “nggak” diubah menjadi “tidak”, kata “bgt” diubah menjadi “banget” dan kata “yg” diubah menjadi “yang”. Hasil output Accuracy pada experimen ini adalah 0.875 atau 87,5% dan Macro-F1 sebesar 0.8431 atau 84,31%. Dari hasil tersebut dapat dilihat bahwa tingkat accuracy dan Macro-F1 pada EXP-1 sedikit lebih tinggi dibandingkan accuracy dan Macro-F1 baseline. Hasil peningkatan ini menunjukkan bahwa normalisasi teks informal dapat membantu menyamakan bentuk kata-kata, sehingga memudahkan model untuk mengenali fitur-fitur yang memiliki makna yang sama. Namun, peningkatannya masih dalam skala yang kecil.

2. Pada experimen EXP-2 yaitu penghapusan stopword dengan menggunakan library sastrawi. Stopword adalah kata umum yang memiliki kontribusi terbatas dalam proses klasifikasi. Pada data ini, kata negasinya yaitu "tidak", "bukan", "belum", "jangan", dan "tak" tetap dipertahankan karena dapat memengaruhi makna sentimen suatu kalimat. Hasil output Accuracy pada experimen ini adalah 0.8723 atau 87,23% dengan Macro-F1 sebesar 0.843 atau 84,3% . Dari hasil tersebut dapat dilihat bahwa accuracynya lebih kecil dari accuracy baseline, sedangkan Macro-F1 sedikit lebih tinggi dibandingkan dengan baseline. Jadi dapat dilihat bahwa dengan adanya penghapusan stopword dapat memberikan pengaruh yang relatif kecil terhadap performa model. Hal ini menunjukkan bahwa tidak semua kata umum dapat dihapus kerena beberapa kata memiliki peran dalam menentukan makna sentimen
3. Pada experimen EXP-3 yaitu proses stemming dengan menggunakan library Sastrawi untuk mengubah kata berimbuhan manjadi dasar. Contohnya seperti "makanan" menjadi "makan", "pelayanan" menjadi "layan", dan "pemandangan" menjadi "pandang". Hasil output Accuracy pada experimen ini adalah 0.8727 atau 87,27% dengan Macro-F1 sebesar 0.8391 atau 83,91%. Dari hasil tersebut dapat dilihat bahwa accuracy dan macro-F1 pada EXP-3 lebih rendah dibandingkan dengan baseline. Jadi penurunan ini menunjukkan bahwa stemming belum memberikan peningkatan pada perform. Salah satu kemungkinan akibatnya adalah perubahan bentuk kata dapat mengurangi informasi yang berguna dalam proses klasifikasi sentimen.
4. Pada experimen EXP-4 yaitu penanganan kata kata negasi dengan menggabungkan negasi dengan kata berikutnya dan menggunakan tanda garis bawah. Misalnya, "tidak menyesal" menjadi "tidak_menyesal". Pada eksperimen ini proses penanganan kata negasi dilakukan setelah normalisasi teks informal dari EXP-1. Hasil output Accuracy pada experimen ini adalah 0.8950 atau 89,50% dengan Macro-F1 sebesar 0.8553 atau 85,53% . Hasil tersebut menunjukkan bawah accuracy dan macro-F1 pada EXP-4 lebih tinggi atau lebih baik dibandingkan baseline dan eksperimen sebelumnya. Hal ini menunjukkan bahwa penanganan negasi dapat membantu model memahami konteks kata kata dalam kalimat, sehingga informasi mengenai perubahan makna sentimen dapat dipertahankan dengan lebih baik.

E. Feature Enrichment

Faeture Enrichment yang dipilih adalah N-gram karena dalam analisis sentimen makna sebuah kalimat tidak selalu ditentukan oleh satu kata saja. Misalnya, kata “bagus” memiliki makna yang positif tetapi kalau digabungkan dengan kata “tidak bagus” berubah menjadi makna negatif. Dengan menggunakan Bigram, model dapat mengetahui kombinasi dua kata yang berdekatan. N-gram dipilih juga karena mudah diterapkan dalam TF-IDF dan tidak memerlukan proses tambahan yang rumit. Karena itu, pengaruh penambahan fitur Bigram dapat diuji secara langsung dengan membandingkan hasilnya dengan Unigram. Berdasarkan hasil output TF-IDF Unigram menunjukan Accuracy sebesar 89,50% dan Macro-F1 sebesar 85,53%. Dari hasil tersebut, terlihat bahwa penambahan Bigram tidak membuat performa model menjadi lebih baik. Justru TF-IDF Unigram menghasilkan nilai Accuracy dan Macro-F1 yang

lebih tinggi. Ini menunjukkan bahwa menggunakan kombinasi dua kata belum tentu memberikan hasil yang lebih baik untuk dataset ini . Terkadang, informasi dari satu kata saja sudah cukup untuk menentukan sentimen dengan akurat.

F. Tahap A Ablation Study

Eksperimen	Preprocessing	Feature	Classifier	Macro-F1
EXP-0	Minimal	TF-IDF Unigram	Logistic Regression	0.8428
EXP-1	Normalization	TF-IDF Unigram	Logistic Regression	0.8431
EXP-2	Normalization + Stopwor Removal	TF-IDF Unigram	Logistic Regression	0.843
EXP-3	Normalization + Stemming	TF-IDF Unigram	Logistic Regression	0.8391
EXP-4	Normalization + Negation Handling	TF-IDF Unigram	Logistic Regression	0.8553

G. Tahap B Model Comparison

Model	Accuracy	Macro-F1	Recall positive	Recall Neutral	Recall Negative
M1-Multinomial NB	0.812273	0.666380	0.9735	0.2217	0.7089
M2 - Logistic Regression	0.895000	0.855282	0.9415	0.6565	0.8879
M3 - Linear SVM	0.906818	0.874847	0.9439	0.7478	0.8908

Precision, Recall, dan F1-score per kelas

```
CLASSIFICATION REPORT - NAIVE BAYES
              precision    recall  f1-score   support

    negative       0.80      0.71      0.75       687
     neutral       1.00      0.22      0.36       230
    positive       0.81      0.97      0.89      1283

    accuracy                           0.81      2200
   macro avg       0.87      0.63      0.67      2200
weighted avg       0.83      0.81      0.79      2200

CLASSIFICATION REPORT - LOGISTIC REGRESSION
              precision    recall  f1-score   support

    negative       0.83      0.89      0.86       687
     neutral       0.94      0.66      0.77       230
    positive       0.93      0.94      0.93      1283

    accuracy                           0.90      2200
   macro avg       0.90      0.83      0.86      2200
weighted avg       0.90      0.90      0.89      2200

CLASSIFICATION REPORT - LINEAR SVM
              precision    recall  f1-score   support

    negative       0.86      0.89      0.87       687
     neutral       0.88      0.75      0.81       230
    positive       0.94      0.94      0.94      1283

    accuracy                           0.91      2200
   macro avg       0.89      0.86      0.87      2200
weighted avg       0.91      0.91      0.91      2200
```

Confusion Matrix

CONFUSION MATRIX - M1 MULTINOMIAL NAIVE BAYES

	Predicted Positive	Predicted Negative	Predicted Neutral
Actual Positive	1249	0	34
Actual Negative	90	51	89
Actual Neutral	200	0	487

CONFUSION MATRIX - M2 LOGISTIC REGRESSION

	Predicted Positive	Predicted Negative	Predicted Neutral
Actual Positive	1208	5	70
Actual Negative	24	151	55
Actual Neutral	73	4	610

CONFUSION MATRIX - M3 LINEAR SVM

	Predicted Positive	Predicted Negative	Predicted Neutral
Actual Positive	1211	9	63
Actual Negative	21	172	37
Actual Neutral	61	14	612

1. Classifer yang menaghasilkan Macro-F1 tertinggi adalah M3 - Linear SVM yaitu 0,8748.
2. Pada data ini Accuracy tertinggi juga memilki Macro-F1 tertinggi yaitu pada classifer M3 - Linear SVM, dengan Accuracy sebesar 0,9068 dan Macro-F1 sebesar 0,8748. Hal ini menunjukkan bahwa model Linear SVM memiliki kinerja yang terbaik secara keseluruhan dan lebih seimbang dalam mengklasifikasi ketiga kelas yaitu negative, positive, dan neutral.
3. Berdasakan hasil recall dan confusion matrix kelas yang paling sulit adalah kelas neutral karena memiliki nilai recall yang paling rendah pada ketigas classifer. Hal ini menunjukkan bahwa masih banyak data neutral yang salah mengklasifikasikan sebagai positive atau negative.
4. Ketiga classifer tidak selalu terjadi kesalahan pada teks yang sama. Dapat dilihat bahwa setiap classifer memiliki pola kesalahan yang berbeda

	Teks	Label Sebenarnya	Naive Bayes	Logistic Regression	Linear SVM	NB Salah	LR Salah	SVM Salah
17	saya dan keluarga mengunjungi paskal food pasa...	positive	positive	negative	positive	False	True	False
24	gue berharap semoga yang lagi menyinyirkan kor...	neutral	negative	negative	negative	True	True	True
28	tempat ini mengimingi makan steak dan daging d...	negative	positive	positive	negative	True	True	False
30	prabowo sama yenny saja ditolak . sabaar ya ro...	negative	positive	negative	negative	True	False	False
45	satu porsi isi 3 batagor . kalau rasa memang s...	positive	positive	negative	negative	False	True	True

5. Pada Tahap A feature engineering meningkatkan Macro-F1 dari 0,8428 menjadi 0,8553, atau naik sebesar 0,0125. Sementara itu pada Tahap B, penggantian model dari Naive Bayes ke Linear SVM meningkatkan skor Macro-F1 dari 0,6664 menjadi 0,8748, atau meningkat sebesar 0,2085. Perubahan metode klasifikasi memiliki dampak yang lebih besar daripada feature engineering .Linear SVM juga menajdi model dengan hasil terbaik dalam pengujian ini.
6. Naive bayes mudah dijelaskan karena menggunakan probabilitas kata untuk menentukan sentimen. Logistic Regression mudah dipahami berdasarkan bobot kata, misalnya kata “bagus” menandakan sentimen positif sedangkan “buruk” menandakan sentimen negatif. Linear SVM lebih sulit dijelaskan karena menentukan sentimen berdasarkan batas keputusan antar kelas.

Kesimpulan Aturan Tuning: Dalam Tahap A, Macro-F1 menunjukkan peningkatan dari 0,8428 menjadi 0,8553. Tetapi pada tahap B, saat model diubah dari Naive Bayes ke Linear SVM, menunjukkan perubahan yaitu Macro-F1 dari 0,6664 menjadi 0,8748. Selain itu, kedua model tersebut menghasilkan hasil yang berbeda untuk mendeteksi

sentimen Neutral. Dengan menunjukkan recall 0,2217, kemudian Logisctic Regression 0,6565, dan yang terakhir Linear SVM 0,7478, hasilnya menandakan bahwa kelas Neutral menjadi kelas yang paling sulit dikenali. Berbeda dengan Accuracy 0,9068 dan Macro-F1 0,8748 Linear SVM yang tetap menjadi model terbaik dari semua percobaan.

H. Trace Satu Prediksi

```
teks asli:
meski masa kampanye sudah selesai , bukan berati habis pula upaya mengerek tingkat kedipilihan elektabilitas .

Hasil Preprocessing:
meski masa kampanye sudah selesai , bukan_berati habis pula upaya mengerek tingkat kedipilihan elektabilitas .

Label sebenarnya:
neutral

HASIL PREDIKSI MODEL
Prediksi Logistic Regression: negative
Prediksi Linear SVM: negative

Skor Logistic Regression:
negative : 0.779279
neutral : -0.19172
positive : -0.58756

Skor Linear SVM:
negative : 0.238958
neutral : -0.506452
positive : -0.873202

LIMA KATA DENGAN KONTRIBUSI TERBESAR
```

	Kata	TF-IDF (xi)	Bobot (wi)	Kontribusi (wi*xi)
12876	selesai	0.3110	0.9722	0.3023
6534	kampanye	0.3924	0.3080	0.1209
5357	habis	0.2623	0.4276	0.1122
8369	masa	0.2773	0.3891	0.1079
13692	sudah	0.1478	0.5150	0.0761

Hasilnya negative karena skor negative lebih tinggi dibandingkan dengan kelas Neutral dan positive. Kata selesai menunjukkan kontribusi paling besar yaitu 0,3023 kemudian diikuti oleh kata lainnya. Setiap kata tersebut meningkatkan skor negative. Namun, model sebenarnya adalah Neutral yang menunjukan bahwa keselurahan konteks kalimat belum mampu dipahami oleh sistem dan lebih mengandalkan pola kata yang muncul dalam teks.

I. Eror Analysis

TABEL ERROR ANALYSIS

	No	Text	Gold	Prediction	Dugaan Penyebab
0	1	meski masa kampanye sudah selesai , bukan berati habis pula upaya mengerek tingkat kedipilihan elektabilitas .	neutral	negative	Ambiguous wording
26	2	kalau melihat desain nya pixel 3 sih biasa saja , tapi iklan nya ini bagus banget sampai bikin barang nya jadi terlihat wah banget	positive	negative	Mixed sentiment
64	3	fpi lagi kerja karena ketua nya perlu makan dan ongkos menginap ngekost di arab . lumayanlan bikin provikasi setiap hari dimedia memang pesanan nya begitu dari burung galak dan sapi dan aki-aki naif	negative	positive	Sarkasme
67	4	bagi anda yang berasal dari jawa tengah , terutama solo dan yogya , mungkin akan cocok dengan rasa makanan yang disajikan di warung sunda ini . karena rasa makanan di warung mak une yang di depan taman pramuka , jalan riau , cenderung manis , layaknya makanan khas jawa solo dan yogya . bahkan sayur asam yang saya pesan pun , juga terasa manis . padahal , seharusnya sayur asam .	negative	positive	Domain-specific term
84	5	untuk kampung daun , tempat unik dan enak buat santai , tapi untuk makanan dan kebersihan sepertinya kurang . karena banyak sarang laba-laba , lalu kucing di mana . __sad__ saya takut kucing . jadi makan juga kurang nyaman .	positive	negative	Mixed sentiment
96	6	bukan cuma jujur , edgar itu banyak dicintai masyarakat dan punya pendirian bagus .	positive	negative	Negasi
98	7	orang yamg paling sulit dinasehati , kayak nya orang yang sedang jatuh cinta .	negative	positive	Ambiguous wording
109	8	harus era hukum nya teh mel . sing bisa kudu dibisa kebun . nomor hiji jagoan demokrat untuk jawa barat hiji .... !!!	positive	neutral	Kata informal/slang
118	9	pas sudah niatan mau protes eh barang nya sampai , dan bagus . aku luluh mbak	positive	negative	Mixed sentiment
128	10	inna lillahi wa inna ilayhi raji un . kaget sekali mendengar kabar pak nusyirwan wakil walikota samarinda meninggal dunia .	neutral	negative	Label ambiguity

Analisis Keberhasilan Preprocessing dan Feature Enrichment

Preprocessing berhasil meningkatkan performa model melalui peningkatan pada EXP-4, tetapi masih terdapat kesalahan terkait negasi dan kata informal yang ditemukan, selain itu feature enrichment EXP-5 dalam penambahan bigram yang belum berhasil karena terjadi penurunan Marco-F1. Sehingga dengan penambahan preprocessing membantu meningkatkan tetapi belum menyelesaikan jenis eror seperti mixes sentiment, ambiguous wording dan sarkasme.

J. Analisis Bias dan Keterbatasan

```
Median panjang teks: 28.0
PERBANDINGAN TEKS PENDEK DAN PANJANG
```

	Kategori	Jumlah Data	Macro-F1	Error Rate (%)
0	Pendek	647	0.8443	13.14
1	Panjang	613	0.7609	8.97

```
PERBANDINGAN TEKS DENGAN DAN TANPA NEGASI
```

	Kategori	Jumlah Data	Macro-F1	Error Rate (%)
0	Dengan Negasi	471	0.8087	12.10
1	Tanpa Negasi	789	0.8503	10.52

Dari kedua perbandingan tersebut, model Linear SVM paling lemah terlihat pada Macro-F1 pada teks panjang dan juga teks yang mengandung negasi. Dari hasil tersebut menunjukkan terdapat keterbatasan model dalam memahami konteks kalimat panjang dan perubahan makna dari penggunaan negasi.

K. Kesimpulan

Jadi pada percobaan kali ini preprocessing yang membantu terdapat pada EXP-4 dengan peningkatan Macro-F1 dari 0,8428 menjadi 0,8553. Sedangkan prerocessing yang tidak membantu terlihat dari EXP-2 dan EXP-3 yang tidak terdapat peningkatan, dengan Macro-F1 yang lebih rendah dari EXP-4 masing-masing sebesar 0,8430 dan 0,8391. Kemudian Featrures Enrichment yang berguna terlihat pada penambahan bigram EXP-5 yang belum membantu karena Macro-F1 menurun menjadi 0,8423. Dari semua percobaan tersebut jenis error terbanyak ada pada mixed sentiment (3 kasus) dan ambiguous wording (2 kasus) dan terdapat beberepa error lainnya. Dari analisis diatas menunjukkan bahwa model memiliki performa yang lebih rendah pada teks panjang dengan Macro-F1 0,7609 dan teks dengan negasi (0,8087) yang menjadi sebuah keterbatasan model dalam memahami konteks kalimat panjang dan penggunaan negasi. Oleh karena itu Pipeline final yang direkomendasikan yaitu dengan normalisasi dan penanganan negasi EXP-4, TF-IDF unigram, dan juga Linear SVM dengan parameter c=1.0 karena performa terbaik terdapat pada accuracy 0,9068 dan Macro-F1 0,8748 dan digunakan sebagai evaluasi akhir dari data validation dengan hasil 1.120 prediksi benar dari 1.260 data.