LAPORAN UTS
PEMROSESAN BAHASA ALAMI (NLP) A

Dosen Pengampu

Dr. Sri Hartati Wijono



DISUSUN OLEH

Nama : Alleyzandra Arthien Thomas

NIM : 245314145

PROGRAM STUDI INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS SANATA DHARMA

YOGYAKARTA

2026

A. DATA AUDIT DAN KARAKTERISTIK DATASET

Eksperimen klasifikasi sentimen ini memakai dataset SmSA (IndoNLU) dengan label positive, neutral, dan negative. train_preprocess.tsv (11.000 sampel) dibagi 80% Train Set dan 20% Development Set dengan stratified split (random_state=42). valid_preprocess.tsv (1.260 sampel) dipakai hanya sebagai Final Evaluation Set dan tidak digabungkan ke training. Seluruh vectorizer di-fit hanya pada Train Set.

Subsets	**Jumlah**	**Distribusi (Pos / Neu / Neg)**	**Catatan**
Raw Train	11.000	6.416 (58,3%) / 1.148 (10,4%) / 3.436 (31,2%)	Jumlah Train + Dev
Train Set (80%)	8.800	5.133 / 918 / 2.749	Basis pelatihan
Development Set (20%)	2.200	1.283 / 230 / 687	Seleksi Tahap A dan B
Final Evaluation Set	1.260	735 (58,3%) / 131 (10,4%) / 394 (31,3%)	Uji akhir satu kali

Karakteristik bahasa (pengamatan pada contoh dan Final Evaluation Set; jumlah kasus: 1.260.

- **Tidak baku, singkatan, dan typo:** bgst, gk, tdk, bgt, yg, ga, ngga; typo seperti "kedipilihan" dan "berati".
- **Negasi:** tidak, bukan, belum, tanpa, jangan (mis. "tidak menyesal", "tanpa bedak", "jangan mau"). Negasi dapat membalik makna, sehingga menjadi risiko bagi model bag-of-words.
- **Tanda baca dan emotikon:** tanda baca terpisah spasi (" , ", " . "), tanda tanya dan seru; emotikon muncul sebagai token kata, mis. "grinningface" dan "__sad__".
- **Code-mixing:** kata Inggris (mostly, work out, deadline, yummy) dan bahasa Sunda (teh, hiji, kudu).

Imbalance, noise, dan bias bahasa. Kelas Neutral hanya 10,4% sehingga model berisiko mengabaikannya. Noise berasal dari duplikat, typo, slang, dan emotikon. Domain teks bercampur (kuliner, politik, produk), sehingga sentimen dapat terikat pada topik tertentu, dan batas kelas Neutral dengan opini halus tipis (label ambiguity). Tidak ada klaim bias demografis karena atribut tersebut tidak tersedia.

B. BASELINE DAN ABLATION STUDY (TAHAP A)

Tahap A mengunci classifier Logistic Regression (max_iter=1000, random_state=42) dan hanya mengubah preprocessing atau fitur. EXP-0: lowercase + normalisasi whitespace + TF-IDF unigram. EXP-1: normalisasi slang dengan kamus 7 entri (gk, tdk, gak, ga → tidak; bgt → banget; yg → yang; dgn → dengan). EXP-2: EXP-1 + stopword NLTK Indonesia dengan negasi (tidak, bukan, belum, tanpa, jangan) dipertahankan. EXP-3: EXP-1 + stemming Sastrawi. EXP-4: EXP-1 + TF-IDF unigram+bigram (feature enrichment n-gram, dipilih karena negasi seperti "tidak bagus" hanya tertangkap sebagai frasa).
Baseline EXP-0 pada Development Set (baris confusion matrix = label gold):

Kelas	Precision	Recall	F1	Confusion (Pos / Neu / Neg)
Positive	0,9030	0,9291	0,9159	1192 / 7 / 84
Neutral	0,9244	0,6913	0,7910	20 / 159 / 51
Negative	0,8093	0,8341	0,8215	108 / 6 / 573

Accuracy 0,8745 dan Macro-F1 0,8428.

Rekapitulasi seluruh eksperimen Tahap A (Development Set; Δ = selisih Macro-F1 terhadap EXP-0):

ID	Pipeline	Accuracy	Macro-F1	F1 Pos	F1 Neu	F1 Neg	Δ
EXP-0	Minimal + TF-IDF unigram + LogReg	0,8745	0,8428	0,9159	0,7910	0,8215	—
EXP-1	EXP-0 + normalisasi slang	0,8755	0,8439	0,9167	0,7930	0,8221	+0,0011
EXP-2	EXP-1 + stopword (negasi dipertahankan)	0,8645	0,8246	0,9106	0,7545	0,8089	−0,0182
EXP-3	EXP-1 + stemming Sastrawi	0,8718	0,8383	0,9124	0,7797	0,8228	−0,0045
EXP-4	EXP-1 + TF-IDF unigram+bigram	0,8727	0,8158	0,9211	0,7000	0,8262	−0,0270

- **EXP-1 (membantu sangat kecil):** Macro-F1 naik 0,0011 (accuracy +0,0010, setara sekitar 2 sampel pada 2.200 data). Arahnya positif, tetapi selisih sekecil ini belum cukup untuk menyimpulkan manfaat yang pasti; kamus hanya 7 entri sehingga sedikit token yang terpengaruh.
- **EXP-2 (merugikan):** Macro-F1 turun 0,0182 dan recall Neutral turun dari 0,6913 menjadi 0,6348, meski negasi dipertahankan. Dugaan: kata fungsi ikut berperan sebagai penanda kelas Neutral; dugaan ini belum diuji langsung. Varian negasi ikut dibuang (EXP-2b) belum diuji pada hasil ini di mana Macro-F1 turun menjadi 0,8001 dan akurasi turun ke 0,8532 dengan *recall* Neutral merosot ke 0,5739.

- **EXP-3 (merugikan):** Macro-F1 turun 0,0045. Stemming menyatukan bentuk kata tetapi dapat menghilangkan nuansa imbuhan (mis. mengecewakan → kecewa); contoh sebelum-sesudah dari data.
- **EXP-4 (merugikan pada LogReg):** Macro-F1 turun 0,0270 karena recall Neutral jatuh dari 0,6913 ke 0,5478 walau precision Neutral naik ke 0,9692; model dengan fitur lebih banyak menjadi lebih konservatif memprediksi Neutral.

Keputusan: berdasarkan Macro-F1 pada Development Set, pipeline terbaik Tahap A adalah EXP-1 (0,8439), sehingga EXP-1 dikunci sebagai feature pipeline untuk Tahap B.

C. MODEL COMPARISON (TAHAP B)

Feature pipeline dikunci pada EXP-1 (normalisasi + TF-IDF unigram) untuk M1 Multinomial NB (alpha=1,0), M2 Logistic Regression (max_iter=1000), dan M3 LinearSVC (C=1,0), dengan split yang sama dan vectorizer hanya di-fit pada Train Set.

Tabel C.1

Model	Accuracy	Macro-F1	Recall Pos	Recall Neu	Recall Neg
M1- Multinomial NB	0,7932	0,6497	0,9587	0,2217	0,7127
M2- Logistic Regression	0,8755	0,8439	0,9306	0,6913	0,8221
M3- Linear SVM	0,8750	0,8486	0,9252	0,7391	0,8232

Tabel C.1. Hasil Tahap B pada Development Set (fitur EXP-1).

Eksperimen tambahan: classifier yang sama dengan fitur EXP-4 (unigram+bigram). Hasil ini diperoleh dari run sebelumnya dan dilaporkan sebagai pembanding, bukan sebagai hasil utama Tahap B.

Model (fitur EXP-4)	Accuracy	Macro-F1	Recall Pos	Recall Neu	Recall Neg
M1 - Multinomial NB	0,7395	0,5332	0,9852	0,0783	0,5022
M2 - Logistic Regression	0,8727	0,8158	0,9462	0,5478	0,8443
M3 - Linear SVM	0,8927	0,8597	0,9423	0,7043	0,8632

Tabel C.2. Hasil tambahan (fitur EXP-4).

Jawaban analisis wajib:

- **1. Macro-F1 tertinggi:** M3 - Linear SVM dengan nilai 0,8486 (diikuti M2 - LogReg sebesar 0,8439 dan M1 - NB sebesar 0,6497. Pada eksperimen tambahan (C.2), Linear SVM tertinggi (0,8597) di atas LogReg (0,8158) dan NB (0,5332).
- **2. Accuracy vs Macro-F1:** Pada Tabel C.1, M1-NB mencatat akurasi 0,7932 tetapi Macro-F1 hanya 0,6497; M2-LogReg mencatat akurasi 0,8755 dengan Macro-F1 0,8439; dan M3-SVM mencatat akurasi 0,8750 dengan Macro-F1 0,8486. Pada C.2 Naive Bayes menunjukkan jarak lebar: accuracy 0,7395 tetapi Macro-F1 0,5332, karena hanya 18 dari 230 data Neutral terdeteksi (recall 0,0783) sementara accuracy didominasi kelas besar.
- **3. Kelas tersulit:** Neutral pada ketiga classifier (C.2: NB 0,0783; LogReg 0,5478; SVM 0,7043). NB juga lemah pada Negative (recall 0,5022; 342 dari 687 diprediksi Positive). Alasan Neutral sulit: kelas minoritas (10,4%) dan batasnya tipis dengan opini halus. NB terdampak paling parah karena prior kelas dan asumsi independensi fitur.
- **4. Kesamaan error:** Statistik error (development set): M1-NB sebanyak 455 salah, M2-LR sebanyak 274 salah, dan M3-SVM sebanyak 275 salah. Terdapat 188 sampel salah di 3 model, 91 sampel salah di 2 model, dan 258 sampel salah di 1 model. Nilai *overlap* antar model tercatat: NB & LR = 220 | LR & SVM = 229 | NB & SVM = 206.
- **5. Dampak feature engineering vs classifier:** Pada Tahap A, selisih Macro-F1 antar-eksperimen hanya 0,0281 (0,8158–0,8439) dan kenaikan terbaik dari baseline hanya +0,0011. Pada C.2, pergantian LogReg → SVM memberi +0,0439 dan NB → LogReg +0,2826. Pergantian classifier berdampak lebih besar daripada preprocessing; konfirmasi dengan Tabel C.1 selisih Macro-F1 antar model pada Tabel C.1: M1 ke M2 sebesar +0,1942, M2 ke M3 sebesar +0,0047. Perbandingan NB → SVM saja kurang adil karena NB gagal pada kelas Neutral.
- **6. Trade-off interpretabilitas:** NB: parameter berupa probabilitas kata per kelas sehingga mudah dibaca, tetapi asumsi independensi membuat kata saling tidak memengaruhi. LogReg: koefisien per fitur dan probabilitas softmax, sehingga keputusan dapat ditelusuri lewat $z = b + \Sigma(w_i \cdot x_i)$. Linear SVM: bobot linear juga bisa dibaca, tetapi keluarannya decision score berbasis margin, bukan probabilitas, sehingga sulit ditafsirkan sebagai tingkat keyakinan.

D. TRACE SATU PREDIKSI

Sampel Development Set indeks ke-0. Raw text: "bagaimana jokoer . sparatis dihai kok diam ? biasanya kalau ada yang demo kalian koar koar seperti kepanasan . payah ! cupu ! perjuangan". Hasil preprocessing: identik dengan raw text (tidak ada kata dalam kamus slang). Gold: negative; prediksi LogReg: negative; intercept kelas negative b = +0,2415.

Fitur (x_i)	TF-IDF (x_i)	Bobot (w_i)	Kontribusi (x_i·w_i)	Arah
payah	0,1972	+1,3923	+0,2746	ke Negative
kok	0,1493	+1,6655	+0,2487	ke Negative
kalian	0,1689	+1,2775	+0,2157	ke Negative
bagaimana	0,1745	+1,1573	+0,2019	ke Negative
koar	0,4980	+0,3062	+0,1525	ke Negative

Total logit per kelas: z(negative) =+1.3349, z(neutral) =-0.4120, z(positive) =1.1200 . Kelas Negative dipilih karena logit-nya tertinggi. Kata seperti payah bermuatan celaan, sedangkan kok,

kalian, dan bagaimana adalah kata fungsi yang pada data latih lebih sering muncul pada teks negatif; model memanfaatkan pola statistik ini, bukan pemahaman sindiran.

Karena model final bukan Logistic Regression, keputusan model final pada contoh yang sama:

- Score SVM per kelas: score(negative) = +1.1852.
  Score(neutral) = -0.3420 , score(positive) = -0.9411
- Penjelasan: kelas dengan skor tertinggi dipilih; skor adalah jarak bertanda ke hyperplane, bukan probilitas.

E. ERROR ANALYSIS (FINAL EVALUATION)

No	Potongan teks	Gold ke Pred	Kategori dan dugaan penyebab
1	meski masa kampanye sudah selesai , bukan berati habis pula upaya mengerek ...	Neutral → Negative	Negasi: kata "bukan" pada berita politik netral dibaca sebagai sinyal negatif.
2	kalau melihat desain nya pixel 3 sih biasa saja , tapi iklan nya ini bagus banget ...	Positive → Negative	Mixed sentiment: kritik di awal, pujian di akhir; model tidak menimbang urutan.
3	... eh di luar ekspektasi , tempat nya ternyata tidak nyaman .	Negative → Positive	Negasi dan idiom: "di luar ekspektasi" terasosiasi positif, "tidak nyaman" tidak cukup kuat.
4	fpi lagi kerja karena ketua nya perlu makan ... lumayanlan bikin provikasi ...	Negative → Positive	Sarkasme: kata "lumayan" bernada pujian, makna negatif tersirat.
5	bagi anda yang berasal dari jawa tengah ... warung sunda ... terasa manis . padahal , seharusnya sayur asam .	Negative → Positive	Ambiguous wording: keluhan implisit tanpa kata negatif eksplisit.
6	untuk kampung daun , tempat unik dan enak ... tapi ... kurang . ... __sad__ saya takut kucing ...	Positive → Negative	Mixed sentiment dan label ambiguity: pujian awal, banyak keluhan; token emotikon __sad__.
7	bukan cuma jujur , edgar itu banyak dicintai masyarakat dan punya pendirian bagus .	Positive → Negative	Negasi: "bukan cuma" adalah penguat positif, bukan pembalik.
8	anies rasyid baswedan tidak mau disingkat jadi arb grinningface ...	Neutral → Negative	Negasi dan emotikon: "tidak mau" dibaca negatif; token grinningface tidak bermakna bagi model.
9	harus era hukum nya teh mel . sing bisa kudu dibisa ... nomor hiji jagoan demokrat ...	Positive → Neutral	Code-mixing Sunda: kata daerah OOV sehingga fitur sentimen lemah.
10	inna lillahi ... kaget sekali mendengar kabar ... meninggal dunia .	Neutral → Negative	Domain-specific dan label ambiguity: berita duka

			berkata negatif, tetapi diberi label netral.

Pola pada 10 contoh: negasi muncul pada 4 contoh (1, 3, 7, 8), mixed sentiment 2, serta sarkasme, ambiguous wording, code-mixing, dan domain-specific masing-masing 1; distribusi pada seluruh 140 error.

Efektivitas perbaikan. Normalisasi slang tidak menyentuh satu pun contoh di atas karena tidak ada kata kamus pada kasus tersebut. Bigram (EXP-4) ditujukan untuk negasi, tetapi contoh 1, 3, 7, dan 8 tetap salah, sehingga bigram belum menyelesaikan error negasi dan frasa seperti "bukan cuma" justru ambigu. Penanganan negasi eksplisit (mis. tidak_bagus) belum dicoba dan menjadi arah perbaikan.

F. ANALISIS BIAS DAN KETERBATASAN

Subset teks	n	Error rate	Macro-F1
Pendek (≤10 kata)	187	0,2674	0,7262
Panjang (>10 kata)	1.073	0,1072	0,8389
Dengan negasi	480	0,1521	0,7943
Tanpa negasi	780	0,1179	0,8460
Dengan slang	141	0,0780	0,5902
Tanpa slang	1.119	0,1376	0,8318

Bentuk bahasa terlemah: **Subset teks dengan slang** (memiliki Macro-F1 terendah yaitu **0,5902**) dan **Subset teks pendek ($\le$10 kata)** dengan *error rate* tertinggi (**0,2674** atau 26,74%). Keterbatasan umum: model bag-of-words tidak menangkap relasi jarak jauh antara negasi dan kata evaluatif, subset slang berukuran kecil sehingga estimasinya tidak stabil, dan seluruh hasil hanya mencakup satu split dan satu random_state.

G. KESIMPULAN DAN REKOMENDASI

1. Preprocessing yang membantu: hanya normalisasi slang (EXP-1) dan itu pun kecil (+0,0011 Macro-F1, sekitar 2 sampel).
2. Yang tidak membantu: *stopword removal* (−0,0182) dan *stemming* Sastrawi (−0,0045); keduanya menurunkan *recall* Neutral.
3. Feature enrichment: *n-gram* unigram+bigram tidak berguna pada Logistic Regression (−0,0270; *recall* Neutral turun ke 0,5478). Manfaatnya untuk classifier lain: M3-SVM meningkat dari Macro-F1 0,8486 (tanpa bigram) menjadi 0,8597 (dengan bigram fitur EXP-4), memberikan kenaikan Macro-F1 sebesar +0,0111.
4. Error dominan: pada 10 contoh yang dianalisis, negasi (4 dari 10) dan *mixed sentiment* (2 dari 10); berdasarkan ekstrapolasi proporsi tersebut pada total 165 error di *Final Evaluation Set* (atau 140 error pada evaluasi sebelumnya), distribusi error didominasi oleh kasus negasi (~40% atau sekitar 66 kasus) dan *mixed sentiment* (~20% atau sekitar 33 kasus), sisanya mencakup sarkasme, *ambiguous wording*, *code-mixing*, dan *domain-specific* (~10% masing-masing).

5. Bias dan keterbatasan: performa terlemah pada subset teks dengan slang (Macro-F1 0,5902) dan subset teks pendek ≤\le≤10 kata (*error rate* tertinggi 0,2674); kelas Neutral tetap tersulit; hasil hanya dari satu *split*.
6. Pipeline rekomendasi: normalisasi slang + TF-IDF unigram + Linear SVM (M3-SVM/M3-SVM-bigram), karena EXP-1 adalah pipeline Tahap A terbaik dan pergantian classifier memberi dampak lebih besar daripada preprocessing. Performa final: *accuracy* 0,8690 dan *Macro-F1* 0,8322 pada Final Evaluation Set; angka *Development Set* tidak boleh dipakai sebagai hasil final.